

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Luiza de Souza Ferreira (RA: 170453)

Repositório: <https://github.com/souza-luiza/redes-neurais/tree/main/projeto1>

1. Configuração Experimental e Reprodutibilidade

1.1. Pré-processamento e Partição dos Dados

O conjunto de dados utilizado possui 300 amostras e duas variáveis, sendo $\mathbf{x}$ o atributo de entrada e y o alvo da tarefa de regressão. Não foram identificados valores ausentes no conjunto de dados.

Os dados foram divididos de forma aleatória em três subconjuntos, utilizando a semente aleatória 42 para garantir a reprodutibilidade dos experimentos. A divisão adotada foi de 10% para treinamento (30 amostras), 10% para validação (30 amostras) e 80% para teste (240 amostras), conforme especificado no projeto.

Para o escalonamento das variáveis, foi empregada a padronização (*Standard Scaling*), dada por

$$z = \frac{x - \mu}{\sigma},$$

em que μ e σ representam, respectivamente, a média e o desvio padrão calculados sobre o conjunto de treinamento. A padronização foi aplicada tanto à variável de entrada $\mathbf{x}$ quanto ao alvo y .

Os parâmetros de padronização foram ajustados exclusivamente sobre o conjunto de treinamento. Posteriormente, os mesmos parâmetros foram utilizados para transformar os conjuntos de validação e teste, evitando vazamento de informações entre as partições (*data leakage*).

Essa configuração resulta em um cenário de poucos dados disponíveis para treinamento, permitindo analisar o comportamento da MLP quanto ao sobreajuste e avaliar o efeito das diferentes técnicas de regularização propostas no estudo de ablação.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* foi definido como uma rede MLP básica treinada com SGD padrão, sem utilização de otimizadores adaptativos e sem termo de *momentum*. Além disso, nenhuma regularização explícita, como L1, L2 ou *Dropout*, foi aplicada nesta fase.

A seleção dos hiperparâmetros foi realizada por meio de uma busca empírica, considerando diferentes arquiteturas, funções de ativação, taxas de aprendizado e tamanhos de lote. Os valores considerados e a configuração final selecionada são apresentados na Tabela 1. O critério de seleção foi o menor MSE obtido no conjunto de validação, mantendo o conjunto de teste isolado durante essa etapa.

Table 1: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida (Vanilla)
Topologia das Camadas	[32], [32, 16], [32, 16, 8]	Entrada $\rightarrow$ Densa(32) $\rightarrow$ Densa(16) $\rightarrow$ Densa(8) $\rightarrow$ Saída(1)
Função de Ativação	ReLU, LeakyReLU, Tanh	LeakyReLU
Otimizador	SGD	SGD
Taxa de aprendizado	0.01, 0.10, 0.15, 0.20	$\eta = 0.15$
Tamanho do Lote	16, 32	16
Função de Custo	MSE	MSE
Critério de Parada	Patience = 20, 30, 50, 100	Patience = 100 épocas
Semente Aleatória	42	Seed = 42

Para sintetizar a comparação entre as arquiteturas avaliadas, a Tabela 2 apresenta, para cada topologia, a configuração que apresentou o menor MSE de validação com *patience* = 100. Observa-se que ocorre uma diminuição no valor do MSE de validação conforme o aumento de camadas na rede. Os MSEs apresentados nesta etapa foram calculados sobre o alvo padronizado.

Table 2: Resultados das arquiteturas avaliadas no modelo baseline.

Arquitetura	Ativação	η	Tamanho do Lote	MSE Treino	MSE Validação	Época
[32]	Tanh	0.15	16	0.693201	0.936030	254
[32, 16]	ReLU	0.20	16	0.672865	0.866460	334
[32, 16, 8]	LeakyReLU	0.15	16	0.585139	0.767351	576

Entre as configurações avaliadas, a arquitetura [32,16,8], com LeakyReLU, $\eta = 0.15$ e tamanho de lote 16, apresentou o menor MSE de validação, igual a 0.767351, sendo selecionada como o modelo baseline para as etapas seguintes.

2. Dinâmica de Treinamento e Convergência (Baseline vs. Modificados)

A Figura 1 apresenta a evolução do erro quadrático médio (MSE) nos conjuntos de treinamento e validação ao longo das épocas para o modelo baseline. Já a Figura 2 apresenta a evolução do MSE no conjunto de validação para o modelo Baseline e para as versões L1, L2, *dropout* e *momentum*. Os valores de MSE apresentados nas curvas estão calculados sobre a variável alvo padronizada.




Figure 1: Convergência da MLP Baseline.




Figure 2: Comparação de convergência dos modelos avaliados no conjunto de validação.

Análise Crítica da Dinâmica de Convergência:

- **Estabilidade do SGD:** A curva de treino e de validação apresentaram alta oscilação ao longo de todas as épocas, conforme mostrado na Figura 1, o que indica que a taxa de aprendizado mostrou-se relativamente alta, fazendo o modelo mudar os pesos rapidamente.
- **Sobreajuste (Overfitting):** O erro de treino e o erro de validação do baseline se descolaram logo no início das épocas. O erro de treino apresentou redução mais acentuada em relação ao erro de validação em determinados períodos do treinamento, indicando diferença entre o ajuste aos dados de treino e a capacidade de generalização. Esse comportamento pode ser favorecido pelo baixo volume de dados disponível para treinamento.
- **Aceleração com Momentum:** A inclusão do momentum reduziu o número de épocas executadas antes da ativação do early stopping, conforme mostrado na Figura 2 pela linha laranja. Para $\beta = 0.5$, a melhor época ocorreu em 44, enquanto o Baseline Vanilla apresentou sua melhor época em 576.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar rigorosamente o efeito de cada componente, a configuração escolhida para o modelo Baseline foi mantida idêntica à da Tabela 1, avaliando-se as seguintes variações individuais:

1. **Baseline + Momentum:** SGD com fator de momentum ($\beta = 0.5, 0.9$).
2. **Baseline + Regularização L2 (Weight Decay):** Penalização quadrática dos pesos ($\lambda_{L2} = 10^{-5}, 10^{-4}, 10^{-3}$).

3. **Baseline + Regularização L1 (Lasso):** Penalização por norma L_1 para incentivo à esparsidade ($\lambda_{L1} = 10^{-3}, 10^{-4}, 10^{-5}$).
4. **Baseline + Dropout:** Desativação aleatória de neurônios nas camadas ocultas ($p = 0.1, 0.2, 0.3$).

Os modelos acima foram analisados com os diferentes valores indicados e os valores com menores MSE de validação foram escolhidos, sendo: $\beta = 0.5$, $\lambda_{L2} = 10^{-5}$, $\lambda_{L1} = 10^{-3}$ e $p = 0.1$.

A avaliação final foi realizada sobre os 80% de dados de teste não utilizados no treino nem no ajuste de hiperparâmetros. Os resultados comparativos estão organizados na Tabela 3, na escala original da variável alvo, onde é possível observar que o modelo Baseline + Regularização L2 apresentou o menor MSE, menor RMSE, menor MAE e maior R^2 no conjunto de teste entre as configurações avaliadas. Além disso, como este foi o único modelo com melhora em relação ao Baseline Vanilla, nenhuma combinação entre as variações analisadas foi feita.

Table 3: Resultados do Estudo de Ablação no Conjunto de Teste (80% dos dados).

Modelo / Variação	MSE	RMSE	MAE	R^2	Melhor Época
Baseline Vanilla (SGD sem momentum)	0.363003	0.602498	0.495242	0.297994	576
Baseline + Momentum ($\beta = 0.5$)	0.474107	0.688554	0.569375	0.083132	44
Baseline + Regularização L2 ($\lambda = 10^{-5}$)	0.347767	0.589718	0.488129	0.327458	651
Baseline + Regularização L1 ($\lambda = 10^{-3}$)	0.459926	0.678179	0.554971	0.110556	168
Baseline + Dropout ($p = 0.1$)	0.459538	0.677892	0.557465	0.111307	309

Na Figura 3, é possível observar a dispersão real comparada com a predição no conjunto de teste do Baseline Vanilla e do Baseline com Regularização L2. Além disso, é possível observar, na Figura 4, a distribuição dos resíduos no conjunto de teste sob o modelo Baseline + Regularização L2, sendo esta a configuração que apresentou o menor MSE de teste entre as variações avaliadas.




Figure 3: Gráfico de paridade entre valores reais e preditos no conjunto de teste do modelo Baseline e Baseline + L2.




Figure 4: Distribuição dos resíduos no conjunto de teste do modelo Baseline + L2.

4. Discussão e Lições Aprendidas

- **Impacto do SGD Vanilla no Regime de Poucos Dados (10% de Treino):** Devido a apenas 10% de dados disponíveis para o treinamento, o Baseline Vanilla apresentou diferenças entre os erros de treinamento e validação, indicando dificuldade de generalização em um cenário

com poucos dados disponíveis para treinamento. Dentre as técnicas avaliadas, a Regularização L2 com $\lambda = 10^{-5}$ apresentou os menores MSE, RMSE e MAE de teste e o maior R^2 entre as configurações avaliadas, conforme apresentado na Tabela 3, além de apresentar o menor MSE de validação entre as configurações de ablação avaliadas.

- **Ação Específica dos Hiperparâmetros de Ablação:**

- O *momentum* ($\beta = 0.5$) alterou significativamente a dinâmica de aprendizado, deslocando a melhor época para 44, em comparação com 576 épocas no Baseline Vanilla, conforme apresentado na Tabela 3. Apesar da redução no número de épocas, o modelo apresentou MSE de teste igual a 0.474107 e $R^2 = 0.083132$, valores inferiores aos obtidos pelo Baseline Vanilla.
- Houve diferença entre as abordagens de regularização L1 e L2. Enquanto a configuração L2 com $\lambda = 10^{-5}$ apresentou redução do erro em relação ao Baseline Vanilla, a configuração L1 com $\lambda = 10^{-3}$ apresentou MSE de teste igual a 0.459926 e $R^2 = 0.110556$, indicando desempenho inferior ao Baseline neste experimento.
- O *Dropout* com $p = 0.1$ apresentou desempenho inferior ao Baseline no conjunto de teste, com $MSE = 0.459538$ e $R^2 = 0.111307$. Nesse cenário de poucos dados para treinamento, a aplicação de *dropout* não resultou em melhora do desempenho de generalização para a configuração avaliada.
- A análise do estudo de ablação revela que, nas configurações avaliadas, o *momentum* e o *dropout* apresentaram desempenho inferior ao Baseline Vanilla no conjunto de teste, enquanto a regularização L2 apresentou redução do erro. Esse resultado indica que, neste cenário de dados reduzidos, a regularização L2 foi a técnica que apresentou melhora em relação ao Baseline.

- **Análise de Resíduos e Limitações:** O gráfico de paridade, mostrado na Figura 3, revela uma concentração de predições em determinadas faixas de Y_{pred} , com destaque para valores próximos de 0.65. Esse comportamento indica uma tendência do modelo a produzir previsões mais concentradas em determinados valores. A Figura 4 apresenta a distribuição dos resíduos do modelo Baseline + L2, com maior concentração de erros em torno de valores negativos e positivos próximos de zero, além da presença de resíduos mais afastados. Esses resultados indicam que o modelo ainda apresenta dificuldade para representar completamente a variabilidade dos dados.