Projeto 2: Compressão de cores com redes SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Luiza de Souza Ferreira (RA: 170453)

Repositório: https://github.com/souza-luiza/redes-neurais/tree/main/projeto2

---

1. Configuração Experimental

1.1. Pré-processamento dos Dados

O arquivo de imagem foi carregado utilizando a biblioteca PIL, garantindo que a imagem possuísse três canais de cores (RGB). Em seguida, a imagem foi convertida em uma matriz NumPy para viabilizar os cálculos posteriores.

Uma normalização dos dados foi realizada para que os valores de cada pixel, originalmente representados por inteiros no intervalo $[0, 255]$, fossem mapeados para o intervalo $[0, 1]$.

Por fim, a estrutura tridimensional da imagem (altura x largura x canais de cores) foi transformada em uma matriz bidimensional. Nessa nova configuração, o número de linhas corresponde ao total de *pixels* da imagem (altura x largura) e o número de colunas é fixado em 3, representando os valores de cada canal RGB.

Além disso, a reprodutibilidade do projeto foi garantida com a definição de uma semente fixa de valor 42.

1.2. Conjunto de Imagens de Teste

Para avaliar a capacidade de generalização e a preservação topológica dos modelos SOM e GNG sob diferentes distribuições no espaço RGB, foram selecionadas quatro imagens de teste de tamanho 500x500 com perfis cromáticos distintos:

- **Pôr do Sol (Gradientes Contínuos):** Caracterizada por transições suaves de cor. Avalia a capacidade de a rede manter a continuidade topológica.
- **Balões Coloridos (Múltiplos Clusters Definidos):** Contém agrupamentos de cores de alto contraste e bem separados. Testa a capacidade de alocação de centroides em agrupamentos densos e isolados.
- **Flor Vermelha (Cores Dominantes vs. Detalhes Raros):** Imagem composta majoritariamente por tons de verde com uma pequena região concentrada em vermelho. Testa se a rede aloca neurônios para representar feições raras ou se é dominada pela massa de dados principal.
- **Floresta (Alta Variabilidade):** Apresenta elevada textura e uma vasta gama de tonalidades complexas, desafiando a capacidade da rede para o limite de compressão e erro de quantização.
- **Retrato de Família (Detalhes Humanos):** Imagem com presença de figuras humanas e variabilidade de textura ao fundo. Avalia a alocação de neurônios para a reconstrução precisa de feições humanas diante de uma vasta massa de dados de fundo.

1.3. *Self-Organizing Maps* (SOM)

O treinamento do SOM foi feito seguindo os seguintes passos: 1) Os pesos RGB de cada neurônio foram gerados aleatoriamente, e suas posições físicas na grade foram mapeadas; 2) A cada iteração, um *pixel* da imagem foi escolhido aleatoriamente, e calculou-se a distância euclidiana entre a cor desse *pixel* e os pesos de todos os neurônios para identificar o neurônio com menor distância, ou seja, o BMU (*Best Matching Unit*); 3) A taxa de aprendizado e o raio máximo de vizinhança sofreram decaimento exponencial ao longo das iterações; 4) Os pesos dos neurônios foram ajustados utilizando uma função de influência gaussiana baseada nas distâncias entre o BMU e os outros neurônios na grade.

As grades do SOM foram construídas conforme as especificações do projeto, testando as dimensões 4x4, 8x8 e 16x16 ($K \in \{16, 64, 256\}$). Os hiperparâmetros adotados foram uma taxa de aprendizado inicial $\eta_0 = 0.5$ e um raio de vizinhança inicial dinâmico definido pela metade do tamanho da linha ou coluna da grade, resultando em $\sigma_0 \in \{2.0, 4.0, 8.0\}$ para as respectivas grades. O número total de iterações de amostragem foi fixado em 40.000. A escolha de σ_0 proporcional à dimensão do grid garante que, no início do treinamento, a função de influência gaussiana cubra a topologia global da rede, permitindo uma ordenação cromática antes do colapso da vizinhança para ajustes locais.

1.4. *Growing Neural Gas* (GNG)

O treinamento do GNG foi feito seguindo os seguintes passos: 1) Os pesos RGB para dois neurônios são escolhidos aleatoriamente, os erros são inicializados com zero e é feita uma conexão entre os dois neurônios iniciais; 2) A cada iteração, um *pixel* é sorteado, os dois neurônios mais próximos são selecionados, e uma conexão entre eles é criada com idade zero, e o erro acumulado do neurônio vencedor é incrementado com base na distância ao quadrado até o *pixel*; 3) O neurônio vencedor e todos os seus vizinhos diretos na rede têm seus pesos RGB ajustados em relação à cor do *pixel* sorteado, utilizando as taxas de aprendizado η_b e η_n, respectivamente; 4) Todas as conexões partindo do neurônio vencedor têm suas idades incrementadas, e conexões que superam a idade máxima (a_{max}) são eliminadas, além de que qualquer neurônio que ficar sem conexões é removido da rede; 5) A cada intervalo de iterações (λ), o algoritmo localiza o neurônio com maior erro acumulado e o seu vizinho também com maior erro acumulado, inserindo um novo neurônio na média entre ambos; 6) Ao final de cada ciclo, os erros de todas as unidades sofrem um decaimento com base no parâmetro β, evitando o acúmulo de erro.

As redes GNG foram construídas conforme as especificações do projeto, testando as dimensões de 16, 64 e 256 neurônios finais. Os hiperparâmetros adotados para os testes foram: $\eta_b = 0.01$, $\eta_n = 0.0001$, idade máxima da aresta (a_{max}) de 90, intervalo de inserção (λ) de 50, $\beta = 0.005$, $\alpha = 0.5$ e 40.000 iterações.

A taxa de aprendizado do vencedor (η_b) foi definida significativamente maior que a dos vizinhos (η_n) para permitir que o neurônio mais próximo lidere a adaptação local sem distorcer drasticamente a topologia ao redor. O equilíbrio entre o intervalo de inserção ($\lambda = 50$) e a idade máxima ($a_{max} = 90$) foi calibrado para permitir que a malha crie novas unidades em regiões densas de cores antes que arestas úteis sejam removidas precocemente. Por fim, os fatores de decaimento α e β atuam no amortecimento dos erros acumulados, evitando a saturação da rede e permitindo que o algoritmo foque nas nuances de cor mais recentes.

1.5. Métricas de Avaliação e Reconstrução Visual

Para mensurar o desempenho dos modelos e visualizar a compressão de cores obtida, foram implementadas duas métricas de validação e um algoritmo de mapeamento inverso, listados a seguir.

- **Erro de Quantização (EQ):** Calcula a distância euclidiana média entre cada *pixel* original da imagem e o peso do neurônio mais próximo (BMU). Ele mede a fidelidade da reconstrução cromática: quanto menor o EQ, mais precisa é a paleta em representar os tons originais.
- **Erro Topográfico (ET):** Avalia a preservação da topologia espacial da rede. Para cada *pixel*, verifica-se se o primeiro (BMU) e o segundo neurônios mais próximos são vizinhos diretos na estrutura geométrica. O ET indica a proporção de dados cujo mapeamento violou a continuidade geométrica (variando de 0 a 1, onde 0 é a preservação perfeita).
- **Reconstrução da Imagem:** Substitui a cor original de cada *pixel* pelo vetor RGB do neurônio vencedor correspondente. Em seguida, desfaz-se a normalização e o achatamento inicial, retornando a matriz ao formato tridimensional original (altura x largura x 3) em formato `uint8` para a exibição da imagem final.

2. Resultados e Análise

2.1. Análise do SOM (Topologia Fixa)

Nas Figuras 1, 2, 3, 4, é possível visualizar a imagem original de pôr do sol, a imagem reconstruída da grade 4x4, a imagem reconstruída da grade 8x8 e a imagem reconstruída da grade 16x16, respectivamente.

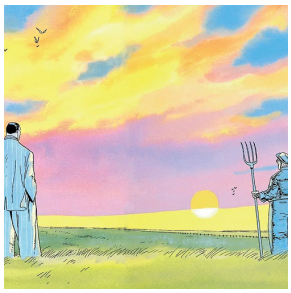


Figure 1: Pôr do Sol.



Figure 2: Grid 4x4.



Figure 3: Grid 8x8.

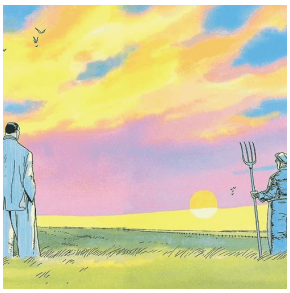


Figure 4: Grid 16x16.

Nas Figuras 5, 6, 7, 8, é possível visualizar a imagem original de balões, a imagem reconstruída da grade 4x4, a imagem reconstruída da grade 8x8 e a imagem reconstruída da grade 16x16, respectivamente.

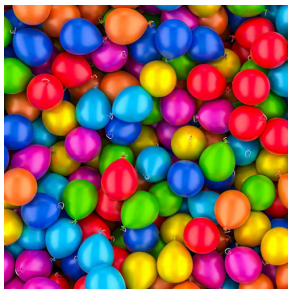


Figure 5: Balões.

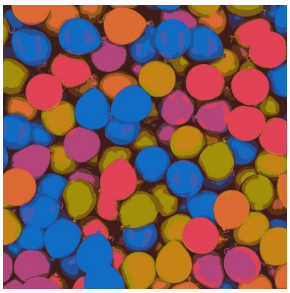


Figure 6: Grid 4x4.

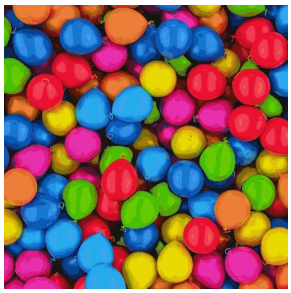


Figure 7: Grid 8x8.

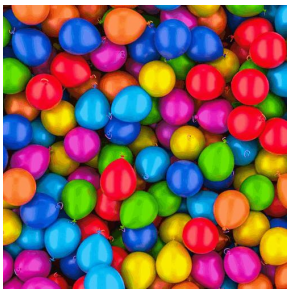


Figure 8: Grid 16x16.

Nas Figuras 9, 10, 11, 12, é possível visualizar a imagem original de flor vermelha, a imagem reconstruída da grade 4x4, a imagem reconstruída da grade 8x8 e a imagem reconstruída da grade 16x16, respectivamente.



Figure 9: Flor.



Figure 10: Grid 4x4.



Figure 11: Grid 8x8.



Figure 12: Grid16x16.

Nas Figuras 13, 14, 15, 16, é possível visualizar a imagem original de floresta, a imagem reconstruída da grade 4x4, a imagem reconstruída da grade 8x8 e a imagem reconstruída da grade 16x16, respectivamente.



Figure 13: Floresta.



Figure 14: Grid 4x4.



Figure 15: Grid 8x8.

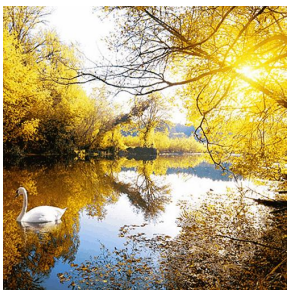


Figure 16: Grid16x16.

Nas Figuras 17, 18, 19, 20, é possível visualizar a imagem original de família, a imagem reconstruída da grade 4x4, a imagem reconstruída da grade 8x8 e a imagem reconstruída da grade 16x16, respectivamente.



Figure 17: Família.



Figure 18: Grid 4x4.



Figure 19: Grid 8x8.



Figure 20: Grid16x16.

Na Tabela 1, é possível visualizar os resultados do modelo SOM em cada imagem de teste.

Table 1: Resultados quantitativos do modelo SOM por imagem de teste e número de cores (K).

Imagem de Teste	K **(Cores)**	E_q **(Quantização)**	E_t **(Topológico)**
Pôr do Sol	16 (4×4)	0.1011	0.0249
	64 (8×8)	0.0523	0.1222
	256 (16×16)	0.0271	0.1565
Balões Coloridos	16 (4×4)	0.2479	0.0601
	64 (8×8)	0.1229	0.0994
	256 (16×16)	0.0557	0.1625
Flor Vermelha	16 (4×4)	0.0535	0.3886
	64 (8×8)	0.0300	0.2117
	256 (16×16)	0.0162	0.3250
Floresta	16 (4×4)	0.1469	0.2537
	64 (8×8)	0.0723	0.1769
	256 (16×16)	0.0435	0.2164
Família	16 (4×4)	0.1591	0.2372
	64 (8×8)	0.0858	0.3178
	256 (16×16)	0.0513	0.2244

2.2. Análise do GNG (Topologia Dinâmica)

Nas Figuras 21, 22, 23, 24, é possível visualizar a imagem original de pôr do sol, a imagem reconstruída com 16 neurônios, a imagem reconstruída com 64 neurônios e a imagem reconstruída com 256 neurônios, respectivamente.

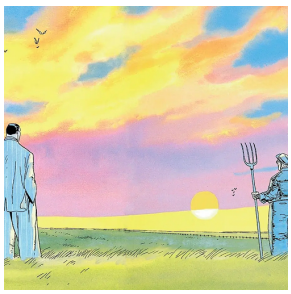


Figure 21: Pôr do sol.



Figure 22: 16 neurônios.

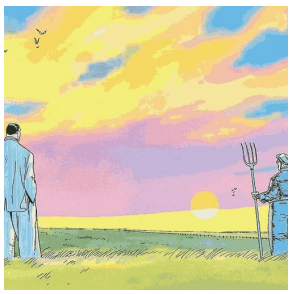


Figure 23: 64 neurônios.

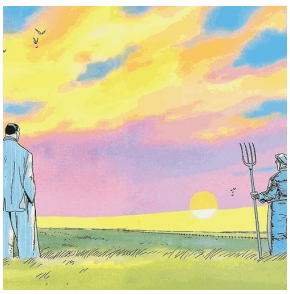


Figure 24: 256 neurônios.

Nas Figuras 25, 26, 27, 28, é possível visualizar a imagem original de balões, a imagem reconstruída com 16 neurônios, a imagem reconstruída com 64 neurônios e a imagem reconstruída com 256 neurônios, respectivamente.

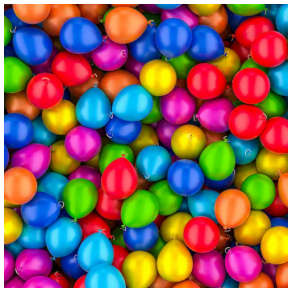


Figure 25: Balões.

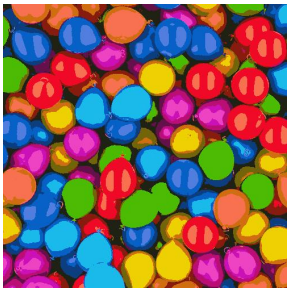


Figure 26: 16 neurônios.

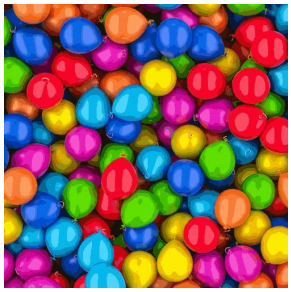


Figure 27: 64 neurônios.

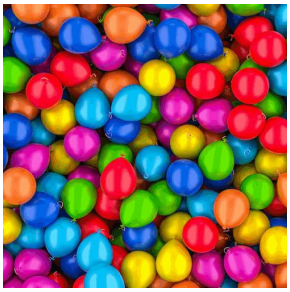


Figure 28: 256 neurônios.

Nas Figuras 29, 30, 31, 32, é possível visualizar a imagem original de flor vermelha, a imagem reconstruída com 16 neurônios, a imagem reconstruída com 64 neurônios e a imagem reconstruída com 256 neurônios, respectivamente.



Figure 29: Flor.



Figure 30: 16 neurônios.



Figure 31: 64 neurônios.



Figure 32: 256 neurônios.

Nas Figuras 33, 34, 35, 36, é possível visualizar a imagem original de floresta, a imagem reconstruída com 16 neurônios, a imagem reconstruída com 64 neurônios e a imagem reconstruída com 256 neurônios, respectivamente.

Nas Figuras 37, 38, 39, 40, é possível visualizar a imagem original de família, a imagem reconstruída com 16 neurônios, a imagem reconstruída com 64 neurônios e a imagem reconstruída com 256 neurônios, respectivamente.

Na Tabela 2, é possível visualizar os resultados do modelo GNG em cada imagem de teste.



Figure 33: Floresta.



Figure 34: 16 neurônios.



Figure 35: 64 neurônios.



Figure 36: 256 neurônios.



Figure 37: Família.



Figure 38: 16 neurônios.

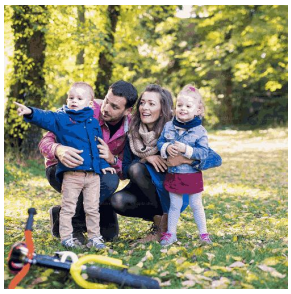


Figure 39: 64 neurônios.



Figure 40: 256 neurônios.

Table 2: Resultados quantitativos do modelo GNG por imagem de teste e número de cores (K).

Imagem de Teste	K **(Cores Reais)**	E_q **(Quantização)**	E_t **(Topológico)**
Pôr do Sol	14	0.0674	0.0008
	37	0.0525	0.0052
	177	0.0336	0.0110
Balões Coloridos	16	0.1439	0.0022
	64	0.0779	0.0068
	249	0.0495	0.0087
Flor Vermelha	14	0.0428	0.0008
	53	0.0278	0.0018
	130	0.0238	0.0038
Floresta	15	0.1064	0.0001
	63	0.0621	0.0039
	252	0.0466	0.0104
Família	16	0.1120	0.0013
	64	0.0687	0.0033
	246	0.0518	0.0106

2.3. Estudo Comparativo: SOM vs. GNG

A análise conjunta dos resultados quantitativos expõe diferenças fundamentais no comportamento do *Self-Organizing Maps* (SOM) e do *Growing Neural Gas* (GNG) frente ao problema de quantização de cores e compressão cromática em espaço $\mathbb{R}^3$.

2.3.1 Fidelidade de Reconstrução (E_q) e Eficiência de Protótipos

Em ambas as arquiteturas, o Erro de Quantização (E_q) decresce com o aumento do número de neurônios (K), conforme ilustrado na Figura 41, visto que uma paleta maior reduz a distância euclidiana média entre os *pixels* originais e seus respectivos *Best Matching Units* (BMUs). Contudo, o GNG demonstrou maior eficiência na alocação de protótipos. Na imagem **Balões**, caracterizada por agrupamentos separados de cores de alto constrate no espaço RGB, o GNG alcançou $E_q = 0.1439$ com apenas 16 neurônios, enquanto o SOM com 16 neurônios na grade 4×4 atingiu $E_q = 0.2479$. Essa eficiência decorre da dinâmica do GNG de inserir unidades estritamente em regiões de alto erro acumulado (λ), concentrando recursos computacionais onde a densidade de variação de cor é mais acentuada.

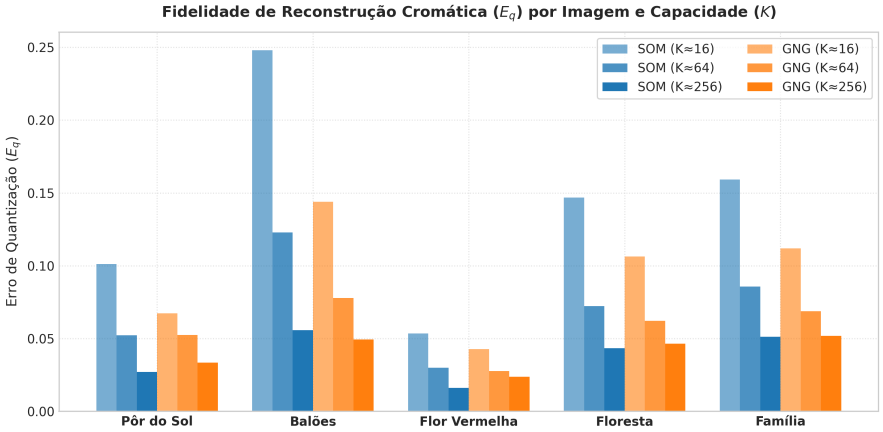


Figure 41: Comparação do Erro de Quantização (E_q) entre os modelos SOM e GNG em todas as imagens de teste para as três variações de neurônios (K).

2.3.2 Preservação Topológica e Rígidez Geométrica (E_t)

A discrepância mais acentuada entre os modelos reside no Erro Topográfico (E_t), como evidencia a Figura 42. O SOM apresentou taxas de E_t significativamente elevadas, variando entre 0.0249 e 0.3886. Notadamente, em duas imagens, o aumento no número de neurônios no SOM resultou no incremento do E_t. Esse fenômeno ocorre devido à rigidez da malha bidimensional do SOM: ao tentar mapear cores tridimensionais complexas e descontínuas sobre uma grade regular 2D, a rede sofre torções e dobras no espaço de pesos, fazendo com que dados adjacentes no espaço RGB sejam atribuídos a neurônios distantes na grade.

Em contrapartida, o GNG obteve um E_t próximo de nulo em todos os cenários ($E_t < 0.0110$). Isso ocorre devido ao GNG construir e destruir conexões dinamicamente com base na proximidade temporal dos dois primeiros BMUs. A topologia do grafo resultante reflete a geometria dos dados no espaço $\mathbb{R}^3$, eliminando arestas inválidas (a_{max}) e preservando a continuidade vizinha sem impor restrições dimensionais estáticas.

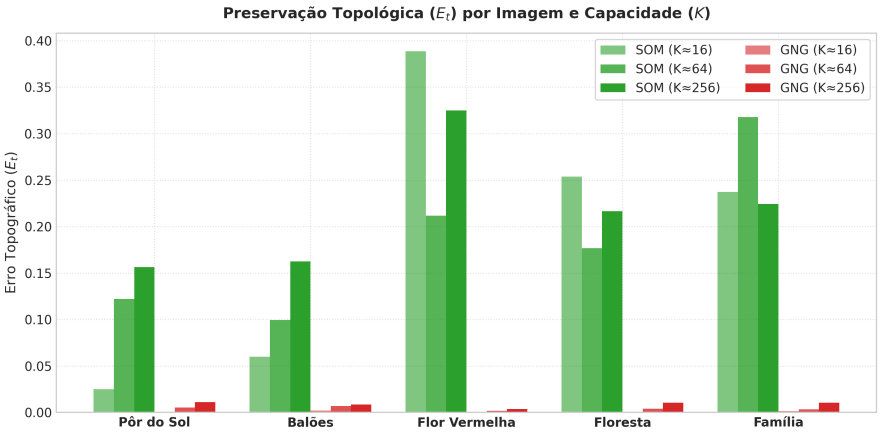


Figure 42: Comparação do Erro Topográfico (E_t) entre SOM e GNG.

2.3.3 Síntese de Desempenho e Compromisso Teórico

- **SOM:** Indicado para mapeamentos bidimensionais estruturados e visualização direta de paletas organizadas em matrizes regulares. Contudo, é vulnerável a dobras topológicas e exige calibragem rigorosa de σ_0 para evitar distorções espaciais.
- **GNG:** Superior para quantização e compressão cromática. A capacidade de adaptar a quantidade de neurônios e a estrutura de conectividade ao formato real da distribuição torna-o mais eficiente para imagens com alta variabilidade local, descontinuidades de contraste ou regiões raras.