Projeto 3: Modelo generativo VAE para MNIST-Fashion

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Luiza de Souza Ferreira (RA: 170453)

Repositório: https://github.com/souza-luiza/redes-neurais/tree/main/projeto3

1. Configuração Experimental

1.1. Pré-processamento e Partição dos Dados

O conjunto de dados Fashion-MNIST é composto por 70.000 imagens em tons de cinza de tamanho 28× 28 pixels, associadas a rótulos que representam 10 classes de artigos de roupas e acessórios. O conjunto original de treinamento tem 60.000 imagens, e foi dividido em 48.000 amostras para treino e 12.000 para validação. O conjunto de teste original permaneceu com 10.000 amostras. Todas as imagens foram convertidas em tensores `PyTorch` e normalizadas para a escala $[0, 1]$. Os dados foram organizados em `DataLoader`, definindo-se o tamanho de lote (*batch size*) em 128 após a etapa de seleção de hiperparâmetros descrita em 1.3, aplicando-se embaralhamento (*shuffle*) apenas ao conjunto de treino. Uma semente aleatória de valor 42 foi fixada para garantir a reprodutibilidade dos experimentos.

1.2. Variational Autoencoder (VAE)

O modelo VAE foi desenvolvido em `PyTorch`, estruturado com camadas lineares e funções de ativação `LeakyReLU` para mapear dados de entrada de 784 dimensões (28 pixels × 28 pixels) em espaços latentes de 2 e 8 dimensões. No `Encoder`, os dados passam por camadas ocultas de 512 e 256 neurônios com ativações LeakyReLU para gerar a média (μ) e a log-variância ($\log \sigma^2$) que parametrizam uma distribuição Gaussiana. A rede foi projetada para estimar a log-variância em vez da variância direta porque a variância, sendo o desvio padrão ao quadrado, deve ser estritamente positiva, assim, ao utilizar o logaritmo, elimina-se a necessidade de restringir a saída da rede a valores positivos.

Utiliza-se o truque de reparametrização para amostrar um ruído aleatório $\epsilon \sim \mathcal{N}(0, 1)$ e, assim, por meio da equação $z = \mu + \epsilon \cdot \sigma$, obter um vetor latente z. Esse vetor é fornecido ao `Decoder` que, espelhando a estrutura do codificador, reconstrói os dados originais mapeando-os de volta para 784 dimensões. Uma ativação `Sigmoid` final é aplicada na última camada do decodificador para garantir que os valores de saída estejam normalizados entre 0 e 1.

A função de perda é definida pela soma do erro de reconstrução (*Binary Cross-Entropy*) e o termo de regularização (Divergência de Kullback-Leibler), conforme apresentado na Equação 1. A *Binary Cross-Entropy* (BCE) mede a diferença pixel a pixel entre a imagem real e a reconstruída pelo modelo. Complementarmente, a Divergência de Kullback-Leibler (KL) penaliza o distanciamento entre a distribuição latente aprendida pelo modelo e uma Gaussiana padrão $\mathcal{N}(0, 1)$.

$$\mathcal{L}(x, \hat{x}, \mu, \sigma^2) = \text{BCE}(x, \hat{x}) + \frac{1}{2} \sum \left(\mu^2 + \sigma^2 - \log(\sigma^2) - 1 \right) \tag{1}$$

1.3. Seleção de Hiperparâmetros

Para identificar a configuração ideal do modelo, realizou-se uma busca avaliando 24 combinações de hiperparâmetros ao longo de 15 épocas cada. A combinação escolhida foi a configuração que obteve a menor perda no conjunto de validação.

Na Tabela 1, são apresentados os hiperparâmetros explorados, bem como a configuração adotada para as dimensões latente de valor 2 e de valor 8.

Após a executação da experimentação, constatou-se que a combinação com $lr = 10^{-3}$, *batch size* de 128, camadas ocultas de $(512, 256)$ e função de ativação `LeakyReLU` forneceu o menor erro de validação tanto para a dimensão 2, sendo 257.2985, quanto para a dimensão 8, sendo 238.9315. Dessa forma, essa configuração foi fixada para o treinamento final de 60 épocas utilizando o otimizador `Adam`.

Table 1: Valores explorados para cada dimensão latente e configuração escolhida.

Hiperparâmetro	Valores Explorados	Configuração Escolhida
Topologia das Camadas	[512, 256], [256, 128]	[512, 256]
Taxa de aprendizado	0.0001, 0.0005, 0.001	0.001
Tamanho do Lote	128, 256	128
Função de ativação	ReLU, LeakyReLU	LeakyReLU

2. Resultados

A Figura 1 apresenta a evolução da função de perda nos conjuntos de treinamento e validação ao longo das épocas para o modelo com dimensão latente igual a 2. Já a Figura 2 apresenta a evolução da função de perda para o modelo com dimensão latente igual a 8. Em ambos os gráficos, a melhor época de treinamento é indicada por uma linha vertical tracejada.

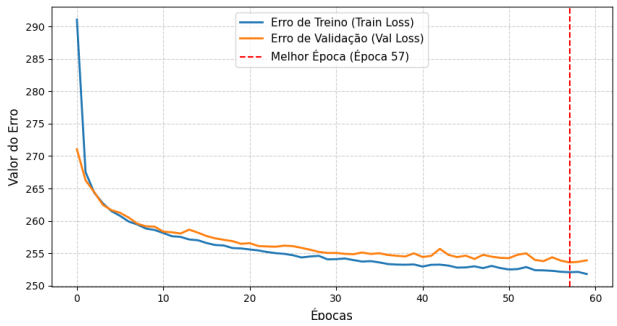


Figure 1: Convergência da dimensão 2.

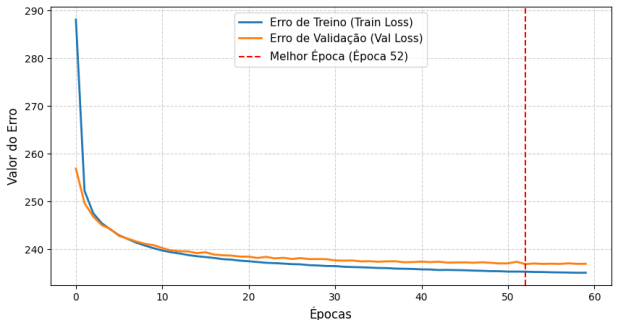


Figure 2: Convergência da dimensão 8.

Na Tabela 2, é possível observar os erros no conjunto de validação e de teste para as duas dimensões analisadas na melhor época de cada modelo.

Table 2: Resultados nos conjuntos de validação e de teste nas dimensões analisadas.

Dimensão	Melhor Época	Loss Validação	Loss Teste
2	57	253.5895	255.0515
8	52	236.8492	238.2544

A Figura 3 exibe a comparação entre imagens originais do conjunto de teste e as respectivas reconstruções geradas pelas duas dimensões latentes analisadas.

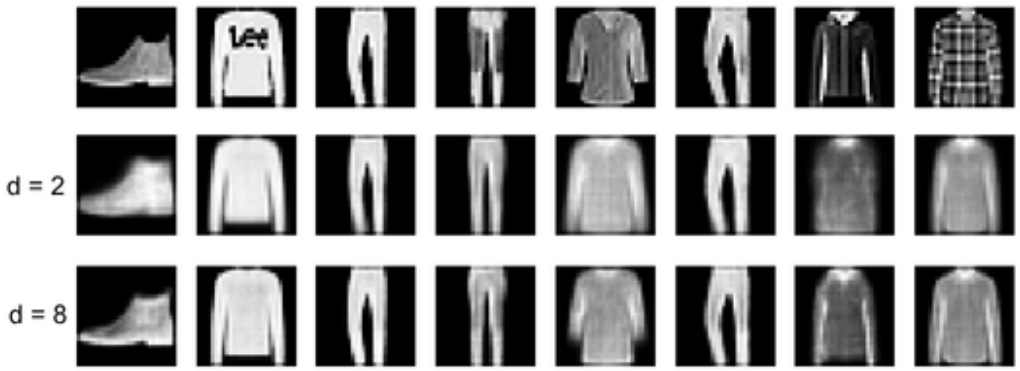


Figure 3: Comparação entre imagens originais e reconstruídas pelo VAE $d = 2$ e $d = 8$.

As Figuras 4 e 5 ilustram novas amostras geradas aleatoriamente a partir do espaço latente de cada modelo.

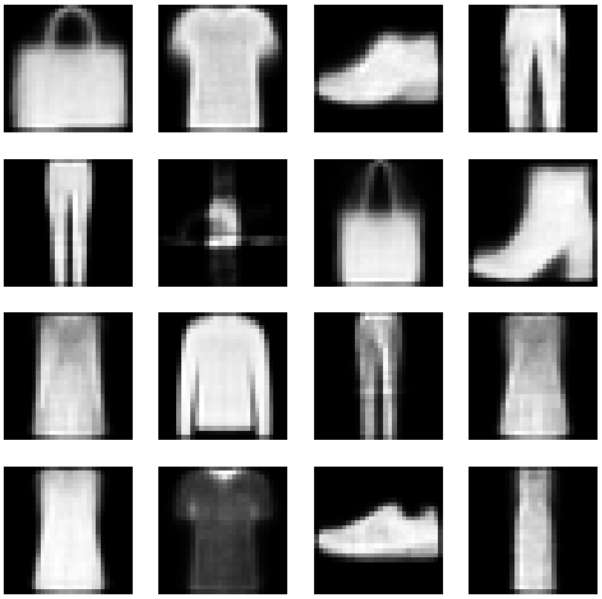


Figure 4: Amostras da dimensão 2.

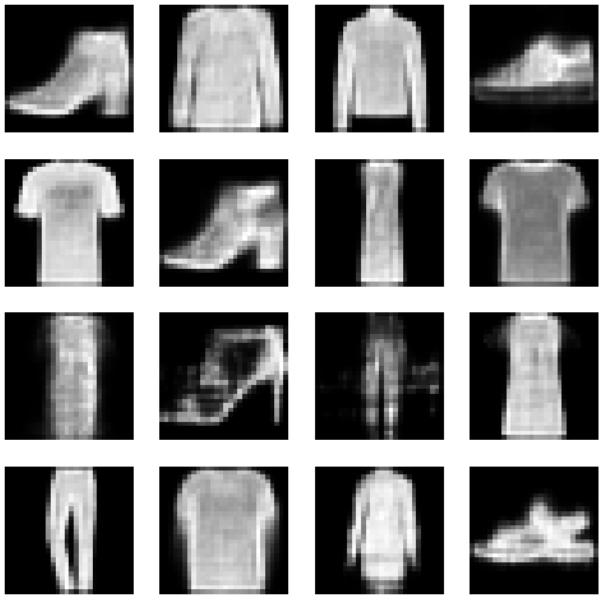


Figure 5: Amostras da dimensão 8.

A distribuição dos dados do conjunto de teste no espaço latente 2D é apresentada na Figura 6.

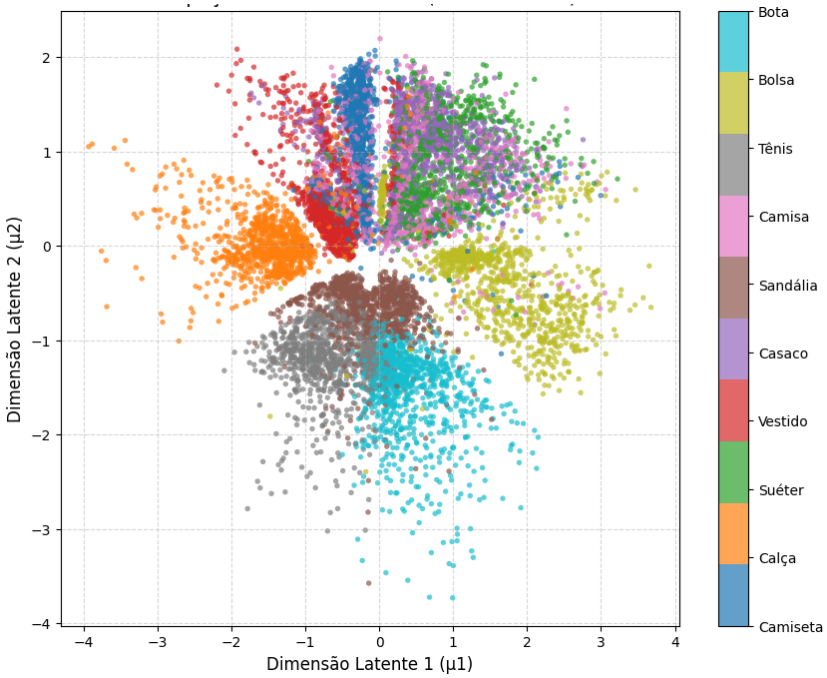


Figure 6: Espaço latente 2D do VAE para o conjunto de teste.

Para o modelo com espaço latente de 8 dimensões, aplicou-se a Análise de Componentes Principais (PCA) para projetar os dados em 2D, conforme mostrado na Figura 7. Porém, a Figura 8 indica que os dois primeiros componentes principais explicam apenas 34,3% da variância total dos dados.

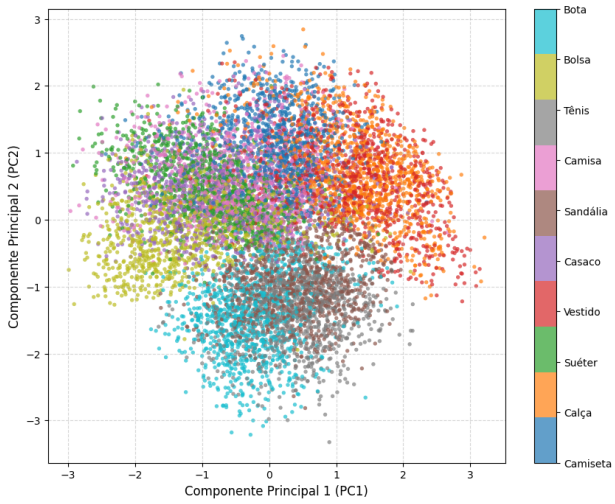


Figure 7: Espaço latente 8D em 2D via PCA.

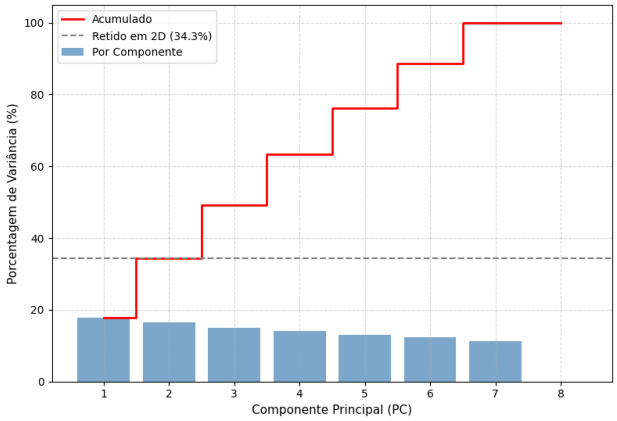


Figure 8: Variância da projeção PCA.

3. Análise dos modelos

3.1. Formação de Clusters e Separação de Rótulos no Espaço Latente

No modelo com espaço latente igual a 2, na Figura 6, observa-se que as classes Camisa, Suéter e Casaco apresentam sobreposição entre si. De maneira análoga, os agrupamentos de Bota, Tênis e Sandália também se posicionam próximos e ligeiramente sobrepostos. Sendo assim, é possível notar que peças visualmente semelhantes apresentam sobreposição entre si, enquanto categorias visualmente distintas são dispostas em agrupamentos afastados.

Na projeção do modelo de dimensão 8,na Figura 7, nota-se que também há uma sobreposição entre peças semelhantes, porém os agrupamentos se apresentam mais próximos entre si no plano projetado.

3.2. Qualidade da Projeção PCA

A análise da Figura 8 mostra que a projeção via PCA do espaço latente 8D, ilustrada na Figura 7, sofre com uma perda significativa de informação. Como os dois primeiros componentes principais explicam apenas 34,3% da variância total, a visualização em duas dimensões descarta cerca de 65,7% da variabilidade original capturada pelo modelo. Portanto, as distâncias reais entre os *clusters* no espaço latente de 8 dimensões são distorcidas ao serem projetadas via PCA com duas dimensões.

3.3. Discussão sobre Desempenho e Reconstrução

A comparação das funções de perda no conjunto de teste, conforme a Tabela 2, indica que o modelo com dimensão latente igual a 8 apresenta um erro inferior ao de dimensão 2. Esse resultado reflete-se nas Figuras 3, 4 e 5, nas quais se observa que o espaço latente de maior dimensão gera imagens com mais detalhes e menor desfoque. Esse comportamento ocorre porque as 8 dimensões têm capacidade para reter mais informações de alta frequência das imagens originais, permitindo ao decodificador realizar uma reconstrução mais fiel e nítida.